

A3 语义表示与对比分析系统实验报告

项目路径：a3/；入口文件：a3/streamlit_app.py；部署方式：GitHub + Streamlit Community Cloud。

一、Vibe Coding Prompt 记录

Prompt 1：使用 Python Streamlit 开发英文语义表示实验平台，包含

TF-IDF/LSA、Word2Vec、GloVe、FastText/Sent2Vec 四个模块，并共用同一份英文语料。

Prompt 2：第一个标签页按句子切分语料，计算 TF-IDF 矩阵，展示 Top 5 关键词，并用 TruncatedSVD 做 LSA 二维可视化。

Prompt 3：第二个标签页使用 gensim 训练 Word2Vec，单选切换 CBOW 与 Skip-Gram，滑动调整 window，输出查询词 Top 5 相似词。

Prompt 4：第三个标签页使用 gensim.downloader 加载 glove-twitter-25，实现 A - B + C 类比和双词相似度。


Prompt 5：第四个标签页训练 FastText，比较 Word2Vec OOV KeyError 与 FastText 子词向量，并用平均池化实现简单 Sent2Vec。

二、核心代码摘录

```
TfidfVectorizer + TruncatedSVD + Word2Vec(sg=0/1) + keyed_vectors.most_similar(positive=[A, C],  
negative=[B]) + FastText + average pooling
```

三、系统运行截图

下列图片为报告配套界面图。实际提交前，可运行 streamlit run streamlit_app.py 后用浏览器截图替换。



A3 Semantic Analysis Lab

Word2Vec Similarity

CBOW / Skip-Gram switch

Query: computer -> model, algorithm, data




A3 Semantic Analysis Lab

GloVe Analogy

king - man + woman -> queen

paris - france + china -> beijing




A3 Semantic Analysis Lab

FastText & Sent2Vec

Word2Vec: OOV KeyError

FastText: vector for computer; sentence cosine



四、实验观察与总结

TF-IDF 能突出小语料中更有区分度的词；LSA

通过矩阵分解把词-文档矩阵压缩到二维空间，便于观察共现结构。

CBOW 与 Skip-Gram 的预测目标不同，因此在小语料实时训练时，同一个查询词的 Top 5 相似词可能发生变化。

GloVe 通过全局共现统计学习词向量， $\text{king} - \text{man} + \text{woman}$

等类比任务可以观察向量空间中的线性语义关系。

FastText 使用字符 n-gram，可以为 computer

这样的拼写错误词生成向量；平均池化句向量虽然简单，但能快速估计句子整体相似度。

提交文件	说明
streamlit_app.py	Streamlit 四模块页面
semantic_core.py	核心算法与工具函数
requirements.txt	部署依赖
A3_实验报告_可打印.html / PDF	实验报告